

Derin Öğrenmede ResNet: Mimarisi, Kullanım Alanları ve Başarıları

1. Giriş

Derin öğrenme modelleri, artan veri setleri ve hesaplama gücü ile birlikte giderek daha derin hale gelmektedir. Ancak, geleneksel sinir ağları katman sayısı arttıkça performans sorunlarıyla karşılaşmaktadır. Bu sorunlardan en önemlisi, **gradyan kaybolması** ve **gradyan patlaması** problemleridir. 2015 yılında **Kaiming He, Xiangyu Zhang, Shaoqing Ren ve Jian Sun** tarafından önerilen **ResNet (Residual Network)** mimarisi, bu problemleri çözmek için geliştirilmiş ve **derin ağların daha stabil bir şekilde eğitilmesini** sağlamıştır [1].

ResNet'in temel yeniliği, **residual bağlantılar** kullanarak derin ağların daha verimli çalışmasını sağlamaktır. Bu bağlantılar, her katmanın çıktısının doğrudan bir sonraki katmana eklenmesiyle oluşur. Böylece, derin ağlarda **bilgi kaybı önlenir** ve **gradyan akışı korunur**. ResNet mimarisi, günümüzde **görüntü sınıflandırma, nesne tespiti ve segmentasyon** gibi çeşitli bilgisayarla görü uygulamalarında yaygın olarak kullanılmaktadır.

2. ResNet Kullanımı

ResNet, farklı alanlarda yaygın olarak kullanılan güçlü bir sinir ağı mimarisidir. Özellikle **görüntü sınıflandırma, nesne tespiti ve segmentasyon** gibi bilgisayarla görü problemlerinde yüksek doğruluk oranları sunmaktadır.

2.1 ResNet'in Görüntü Sınıflandırmada Kullanımı

ResNet, **ImageNet** gibi büyük veri setlerinde görüntü sınıflandırma problemleri için üstün performans göstermektedir. Bu modelin başlıca kullanım yöntemleri şunlardır:

- **Önceden Eğitilmiş Model Kullanımı:** TensorFlow ve PyTorch gibi kütüphaneler, ResNet'in önceden eğitilmiş versiyonlarını sunmaktadır. **Transfer öğrenme** yöntemi ile bu modeller, farklı veri kümelerine adapte edilebilir.
- **Özel Veri Seti ile Eğitme:** ResNet, sıfırdan eğitilebilir veya son katmanları değiştirilerek belirli bir problem için optimize edilebilir.
- **Özellik Çıkarımı:** Derin katmanları sayesinde yüksek seviyeli özellikler çıkarılabilir. Bu yöntem, özellikle **medikal görüntü analizi ve sahne tanıma** gibi alanlarda tercih edilmektedir.

2.2 ResNet ile Nesne Tespiti ve Segmentasyon

ResNet, **Faster R-CNN, Mask R-CNN ve YOLO** gibi popüler nesne tespiti ve segmentasyon modellerinde temel bileşen olarak kullanılmaktadır. Bu uygulamalardaki başlıca avantajları şunlardır:

- **Derin Özellik Haritaları:** ResNet, çok katmanlı yapısı sayesinde **daha detaylı ve anlamlı özellik haritaları** oluşturur.
- **Verimli Hesaplama:** Residual bağlantılar sayesinde **eğitim süreci stabil hale gelir** ve **hesaplama maliyeti düşer**.
- **Transfer Öğrenme Desteği:** ResNet, **farklı veri setleri ve uygulamalar** için kolayca adapte edilebilir.

Örneğin, **Mask R-CNN** modeli, ResNet'i arka plan mimarisi olarak kullanarak **piksel bazlı nesne segmentasyonu** yapabilmektedir. Bu yaklaşım, **otonom araçlar, tıbbi görüntüleme ve yüz tanıma** gibi alanlarda büyük avantajlar sağlamaktadır [2].

3. ResNet'in Avantajları

ResNet, geleneksel sinir ağı mimarilerine kıyasla birçok avantaja sahiptir:

- **Daha Derin Ağlar Eğitme Yeteneği:** Residual bağlantılar sayesinde **çok derin ağlar** stabil bir şekilde eğitilebilir.
- **Gradyan Kaybolma Problemini Önleme:** ResNet'in residual bağlantıları, **gradyanların korunmasını** sağlayarak modelin daha hızlı ve stabil öğrenmesini destekler.
- **Transfer Öğrenmeye Uygunluk:** Önceden eğitilmiş ResNet modelleri, transfer öğrenme yöntemiyle **farklı problemler için kolayca adapte edilebilir**.
- **Yüksek Performans:** ResNet, **ImageNet ve COCO** gibi büyük veri setlerinde **yüksek doğruluk oranları** elde etmiş ve **görüntü sınıflandırma, nesne tespiti ve segmentasyon** gibi birçok bilgisayarla görü uygulamasında temel mimari olarak kullanılmaktadır.

4. ResNet'in Başarıları

ResNet, derin öğrenme alanında birçok önemli başarı elde etmiştir.

4.1 ImageNet Yarışması (ILSVRC 2015) ve ResNet'in Başarısı

2015 yılında **ImageNet Büyük Ölçekli Görsel Tanıma Yarışması (ILSVRC)** kapsamında ResNet-152 modeli, **sadece %3,57 hata oranı** ile **birincilik kazanmıştır** [3]. Bu oran, insan seviyesindeki hata oranına oldukça yakındır ve derin öğrenme modellerinin performansındaki önemli bir artışı temsil etmektedir.

4.2 Derin Öğrenmede Yapısal Gelişmeler

ResNet'in başarısı, **daha derin ağların eğitilmesini** mümkün kılmış ve **VGGNet gibi önceki derin öğrenme modellerine kıyasla daha yüksek doğruluk oranları** elde edilmesini sağlamıştır. **Residual bağlantılar**, günümüzde birçok modern modelin temel bileşeni haline gelmiştir.

4.3 Endüstride Kullanım Alanları

ResNet, akademik başarısının yanı sıra **endüstride de yaygın olarak kullanılmaktadır**. Özellikle:

- **Otonom Araçlar:** ResNet, nesne tespiti ve segmentasyon için **otonom araçlarda yaygın olarak kullanılmaktadır**.
- **Tıbbi Görüntüleme:** ResNet, **MR ve röntgen görüntülerinin analizinde** kullanılmaktadır.
- **Yüz Tanıma Sistemleri:** ResNet tabanlı modeller, yüz tanıma uygulamalarında **daha yüksek doğruluk oranları** sunmaktadır.

5. Sonuç

ResNet, **derin sinir ağlarının eğitilmesinde karşılaşılan temel problemleri** çözerek **modern bilgisayarla görü uygulamalarında devrim niteliğinde bir gelişme sağlamıştır**. Özellikle **residual bağlantılar**, günümüzde derin öğrenme modellerinin **daha stabil ve verimli bir şekilde eğitilmesini** mümkün kılmıştır.

ResNet'in başarısı, **görüntü sınıflandırma, nesne tespiti ve segmentasyon** gibi birçok alanda kendini kanıtlamış ve akademik dünyada olduğu kadar endüstride de büyük yankı uyandırmıştır. Günümüzde ResNet, **yapay zeka tabanlı sistemlerin temel yapı taşlarından biri olmaya devam etmektedir.**

Kaynaklar

- [1] He, K., Zhang, X., Ren, S., & Sun, J. (2016). *Deep Residual Learning for Image Recognition*. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 770-778. <https://doi.org/10.1109/CVPR.2016.90>
- [2] Ren, S., He, K., Girshick, R., & Sun, J. (2017). *Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks*. IEEE Transactions on Pattern Analysis and Machine Intelligence, 39(6), 1137-1149. <https://doi.org/10.1109/TPAMI.2016.2577031>
- [3] Russakovsky, O., Deng, J., Su, H., Krause, J., Satheesh, S., Ma, S., ... & Fei-Fei, L. (2015). *ImageNet Large Scale Visual Recognition Challenge*. International Journal of Computer Vision, 115(3), 211-252. <https://doi.org/10.1007/s11263-015-0816-y>
- [4] (Cireşan et al., 2011; He et al., 2016; Huang et al., 2017; Krizhevsky et al., 2017; Mustafa Serdar Konca, 2024; Redmon, 2016; Szegedy et al., 2016)